FACULTAD DE CIENCIAS EXACTAS UNICEN

Fundamentos de la Ciencia de Datos 2026

TRABAJO PRACTICO ESPECIAL

Grupo 41

Cordoba Pablo Javier
Lopez Gonzalo
Scuncio Maria Paz

INTRODUCCION

Contexto sobre el espacio del problema

El mundo de la tecnología y el desarrollo de software cambia rápido. Hoy en día, tomar decisiones acertadas sobre sueldos, contratación de personal, qué lenguajes aprender o cómo adoptar tecnologías nuevas (como la Inteligencia Artificial) requiere mirar datos reales sobre lo que pasa en la industria.

A partir de la información de la encuesta, este trabajo busca explorar y entender la realidad laboral y profesional de los desarrolladores tomando como base la encuesta anual Stack Overflow Developer Survey 2025



Para abordar la complejidad de las 172 variables recolectadas en la encuesta, el espacio del problema se estructura en torno a 6 módulos o grupos temáticos principales:

1. **Developers (Perfil, Educación y Roles):**
Estudio de las caracteristicas sociodemograficas, nivel de formación, años de experiencia programando y puestos de trabajo dentro de la industria (Age, EdLevel, WorkExp, YearsCode, DevType, Country, etc.).

2. **Technology (Tecnologia y Herramientas):**
Análisis del uso actual, deseo de aprendizaje futuro y grado de admiración respecto a lenguajes, bases de datos, plataformas, entornos e infraestructura de desarrollo (Language, Database, Platform, OpSys, etc.).

3. **AI (Inteligencia Artificial):**
Evaluación del grado de adopción, modelos utilizados, herramientas de asistencia, percepción de amenaza o beneficio y niveles de confianza/frustración con los agentes de IA (AIModels, AIAgent, AITool, AIThreat, etc.).

4. **Work (Entorno Laboral, Salarios, Satisfaccion):** Caracterización de las condiciones de empleo, esquemas de trabajo (remoto, híbrido, presencial), industrias, salario anuales (ConvertedCompYearly) y factores clave de satisfaccion laboral (JobSat, JobSatPoints).

5. **Stack Overflow (Comunidad y uso):** Medición de la frecuencia de visita, nivel de participación activa, sentimiento de pertenencia y dinámicas de interacción de los desarrolladores con la plataforma (SOVisitFreq, SOPartFreq, SOComm, etc.).

6. **Methodology (Practicas y percepción tecnologica):** Indagación sobre las actitudes, adhesión o rechazo hacia metodologías de desarrollo, buenas prácticas de ingeniería y la tendencia a cambiar de rol o de rumbo profesional (TechEndorse, TechOppose, NewRole).

Descripción y Origen del Conjunto de Datos

Para llevar a cabo este estudio se utilizó la base de datos oficial de la encuesta Stack Overflow Developer Survey 2025.

A partir de la documentación pública brindada por Stack Overflow en su sitio web oficial, podemos caracterizar los aspectos clave:

- **¿Qué es?:** Es una encuesta de alcance global que la plataforma Stack Overflow realiza de manera anual desde el año 2011. Su objetivo es medir el estado actual de la industria del software, las tendencias tecnológicas, las herramientas emergentes, los salarios y los hábitos de la comunidad internacional de desarrolladores.

- **Población Objetivo:** Responden estudiantes, aficionados, programadores profesionales, ingenieros y especialistas de datos de todo el mundo.

- **Tipo de Muestreo:** Corresponde a un muestreo no probabilístico por autoselección voluntaria. Esto implica que responden únicamente aquellas personas que deciden ingresar activamente al cuestionario.

Estructura de Archivos

La información provista por Stack Overflow se distribuye en dos archivos principales que componen el dataset:

1. **results.csv (tabla de respuestas):** Contiene las 49.191 filas recopiladas y 172 columnas. Ocupa aproximadamente 375,2MB en memoria y cada fila representa el registro anónimo e individual de un encuestado.

2. **schema.csv (diccionario de metadatos):** Contiene la información técnica del cuestionario. Asocia la clave de la pregunta (qname) con el texto largo del enunciado presentado al usuario en la web (question) y el tipo o formato de la pregunta (type: Multiple Choice, Rank Order, Matrix, etc.).





Utilidad e Importancia del Dataset

En Ciencia de Datos, este conjunto de información es clave porque nos da una foto con números reales de la industria. Nos permite medir con datos concretos aspectos como:

- **Perfiles Demográficos:** Analizar edades, niveles educativos alcanzados, roles de trabajo y distribución geográfica.

- **Trayectoria y Modalidad Laboral:** Evaluar los años acumulados de experiencia programando y trabajando (YearsCode, WorkExp), junto con los esquemas de trabajo (remoto, presencial o híbrido).

- **Compensación Económica:** Estudiar ingresos anuales en dólares estadounidenses (ConvertedCompYearly) para entender el rango salarial de la industria.

- **Adopción de Tecnologías e Inteligencia Artificial:** Medir el uso, interés futuro y nivel de satisfacción de herramientas tradicionales (lenguajes, bases de datos, entornos) y tecnologías emergentes (asistentes, agentes y modelos de IA generativa).

Problemas Identificados y Solucion

Durante las etapas de carga y vinculación de los datos, identificamos diversas particularidades estructurales y desafíos de calidad que requerían un tratamiento adecuado.

1 Vinculación entre las respuestas y las preguntas de la encuesta

⚠ **Problema**: Al cruzar las 172 columnas del archivo de respuestas con el diccionario de preguntas, descubrimos que solo 126 columnas coincidían de forma directa con un código qname del esquema. Quedaban 46 columnas que no cruzaban a simple vista debido a modificaciones de nombre realizadas al exportar la encuesta.

💡 **Solución**: En lugar de hacer una vinculación manual, diseñamos en Python una función algorítmica por prefijos (raiz_mas_larga). Esto nos permitió asociar esas 46 columnas con su pregunta madre en el esquema y clasificarlas funcionalmente en 5 grupos:

Clave Primaria: ResponseId (identificador técnico e anónimo).

Variable Calculada: ConvertedCompYearly (salario anualizado en USD derivado de CompTotal y Currency).

Facetas Tecnológicas: Bloques de herramientas desglosados en tres aspectos de experiencia: uso actual (HaveWorkedWith), interés futuro (WantToWorkWith) y valoración de calidad (Admired).

Ámbito de Uso: Diferenciación de sistemas operativos entre uso personal y laboral (OpSysPersonal use / OpSysProfessional use).

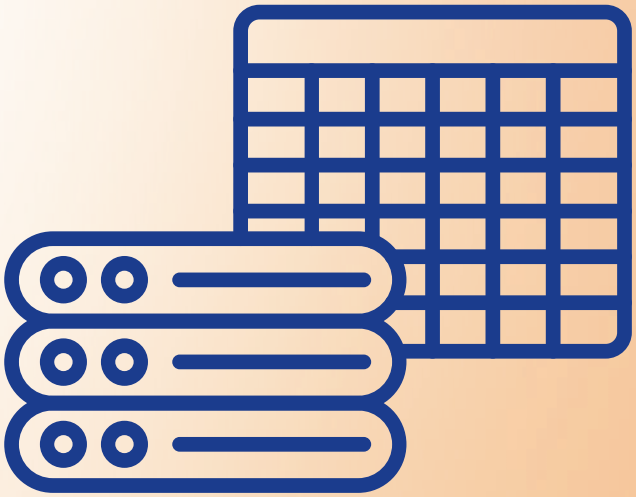
Matrices y Escalas Likert: Opciones de respuesta aplanadas sobre la adopción, impacto y desafíos de la Inteligencia Artificial.



2 Detección de Nulos Estructurales por Lógica de Interfaz

⚠ **Problema**: Módulos completos como Technology o AI presentaban porcentajes promedio de valores nulos muy elevados

Solución: Al cruzar los datos mediante tablas de contingencia, comprobamos directamente en los datos que estos valores vacíos no son errores de medición ni respuestas perdidas por accidente. Se deben simplemente a la lógica de saltos de la encuesta web: si un usuario responde que no usa herramientas de Inteligencia Artificial en la pregunta filtro (AIModelsChoice), el formulario saltea automáticamente todas las preguntas detalladas sobre modelos o agentes. Para no borrar a esos encuestados ni arruinar la muestra, completamos esos casilleros vacíos con la etiqueta "No aplica / No utiliza" en las 60 columnas condicionales de tecnología e IA.



3 Limpieza de Incoherencias y Valores Fuera de Rango

⚠ **Problema:** Al analizar la distribución de las variables cuantitativas, detectamos dos tipos de anomalías:

- Inconsistencias Lógicas Severas: 3.564 casos donde los años de experiencia laboral declarados superaban a los años totales programando (WorkExp > YearsCode), lo cual constituye un error físico en la respuesta.
- Outliers Extremos: Salarios anuales atípicos o spam (menor a $100 USD o mayor a $2.000.000$ USD) y años de programación ilógicos (mayores a 60 años).

💡 **Solucion**:

- Para las inconsistencias lógicas severas (WorkExp > YearsCode), eliminamos esas filas por representar datos irrecuperables.
- Para los salarios y años extremos, re-categorizamos esas celdas individuales como NaN en lugar de borrar la fila completa del encuestado.

Balance General de Limpieza

Gracias a este criterio de conservación de datos, pasamos de 49.191 filas originales a 45.627 filas limpias finales, garantizando una tasa de retención del 92,75% de la muestra total.

Organización del Trabajo y Estructura del Informe

Para analizar los datos de forma ordenada y cumplir con todos los requerimientos de la cátedra, organizamos este trabajo en cuatro secciones principales:

1. **Sección 1: Introducción y Contextualización de los Datos**
   Presentamos el tema central del estudio, describimos la base de datos utilizada y explicamos cómo relacionamos cada columna con el diccionario original schema.csv. Además, señalamos los primeros desafíos observados en los datos, como valores faltantes y diferencias en la estructura de las variables.

2. **Sección 2: Análisis Exploratorio y Limpieza de Datos**
   Clasificamos las 172 variables según su tipo estadístico, analizamos dónde y por qué faltan datos (diferenciando omisiones voluntarias de la propia lógica de la encuesta) y aplicamos criterios de limpieza para tratar errores e inconsistencias (como sueldos o años de experiencia fuera de rango).

3 **Sección 3: Planteo y Validación de Hipótesis**

Evaluamos las preguntas clave del trabajo combinando gráficos y estadísticas descriptivas. Poniendo a prueba las hipótesis solicitadas y las propias, analizamos temas centrales como los salarios (ConvertedCompYearly), los años de experiencia (WorkExp, YearsCodePro), la postura frente a la inteligencia artificial (AIThreat, AIAgentImpact) y el nivel de satisfacción laboral.

4 **Sección 4: Conclusiones Finales**

Resumimos los hallazgos más importantes sobre la realidad de los desarrolladores a nivel global y local. También reflexionamos sobre las limitaciones del estudio, considerando que la encuesta fue respondida de forma voluntaria.



ANÁLISIS EXPLORATORIO DE LOS DATOS

Para comprender la estructura, calidad e integridad de la información provista por la encuesta Stack Overflow Developer Survey 2025, se ejecutó un Análisis Exploratorio de Datos (EDA) exhaustivo en el cuaderno de código adjunto. Este proceso abarcó la evaluación de dimensiones, la clasificación metodológica y temática de los atributos, la cuantificación e interpretación de valores nulos, la distribución de variables cuantitativas y cualitativas, y la posterior aplicación de reglas de limpieza y calidad de datos.



Ingesta Inicial y Trazabilidad de Atributos (results vs. schema)

El dataset principal de respuestas (**results.csv**) contiene originalmente 49.191 registros (filas) y 172 atributos (columnas), representando un volumen de memoria de aproximadamente 114,3 MB. Por su parte, el diccionario oficial (**schema.csv**) posee 130 entradas que detallan el enunciado de las preguntas (**question**) y el formato del formulario (**type**).

Al cruzar los identificadores claves del esquema (**qname**) con las columnas del dataset de respuestas, se observó que únicamente 126 columnas coincidían directamente de forma exacta. Para demostrar la trazabilidad del 100% de la muestra y descartar la presencia de errores de exportación, se diseñó un algoritmo de extracción de raíz y análisis de sufijos.

Como se resume en la Tabla 1, se logró categorizar con éxito las 46 columnas huérfanas o desglosadas:

Categoria Funcional	Cantidad de Variables	Ejemplos / Sufijos Asociados	Descripcion / Proposito
Clave Primaria (PK)	1	ResponseId	Identificador único del encuestado.
Variable Calculada	1	ConvertedCompYearly	Ingreso anual estandarizado en USD.
Faceta de Technologia	27	HaveWorkedWith, WantToWorkWith, Admired	Desglose de uso actual, interés futuro y admiración.
Ambito de Uso	2	Personal use, Professional use	Entorno de aplicación de sistemas operativos (OpSys).
Opción Likert / Matriz	15	AIAgentImpact..., AIAgentChallenges...	Opciones aplanadas de tablas o matrices de opinión.

Tabla 1: Clasificación funcional de las 46 variables desglosadas y sintéticas de results.csv

Clasificación Estadística y Agrupación Temática

Para estructurar el análisis y entender bien con qué datos estamos trabajando, armamos un diccionario de variables (**df_variables**). Esta tabla reúne las 172 columnas de la encuesta (**results.csv**) y las relaciona directamente con la pregunta original (**question**), el tipo de campo en el formulario (**type**) y cómo las interpreta Python (**dtype**).

Clasificación por Tipo de Pregunta y Escala Estadística

Al evaluar la columna **type** proveniente de **schema.csv** sobre el total de las 172 columnas de la base de datos, se obtuvo la siguiente distribución de formatos y su equivalente en la teoría estadística:

1. Ordenamiento / Ranking (**RO** - 49 columnas): Preguntas de orden de preferencia o jerarquización. Corresponden en su totalidad a variables cualitativas ordinales, ya que evalúan posiciones relativas dentro de una escala.

2 Selección Múltiple o Simple (**MC** - 48 columnas): Opciones cerradas simples (como **MainBranch** o **Employment**) y listas de selección múltiple concatenadas con punto y coma (como **LanguageHaveWorkedWith**). Se clasifican como variables cualitativas nominales (algunas de ellas multivaluadas).

3 Matrices y Escalas Likert (**Matrix** - 44 columnas): Tablas aplanadas de evaluación de percepción, nivel de acuerdo, satisfacción o frecuencia (ej., preguntas sobre agentes o herramientas de IA). Constituyen variables cualitativas ordinales.

4 Entrada de Texto y Números (**TE** - 29 columnas): Campos de ingreso directo que abarcan tanto variables cuantitativas discretas (como **WorkExp** o **YearsCode**) y cuantitativas continuas (como **CompTotal**), así como cadenas de texto libre.

5 Variables sin type asignado (**NaN** - 2 columnas): La clave primaria técnica **ResponseId** (identificador único del encuestado) y la variable calculada de ingresos anuales estandarizados **ConvertedCompYearly**.

Agrupación Temática por Dominios

Siguiendo la arquitectura del informe oficial de Stack Overflow, las 172 variables se organizaron algorítmicamente en 6 módulos temáticos principales dentro del diccionario **df_variables**:

Developers (12 variables): Contempla el perfil sociodemográfico, educación, experiencia y rol profesional del encuestado (ResponseId, MainBranch, Age, Country, EdLevel, WorkExp, YearsCode, LearnCode, etc.).

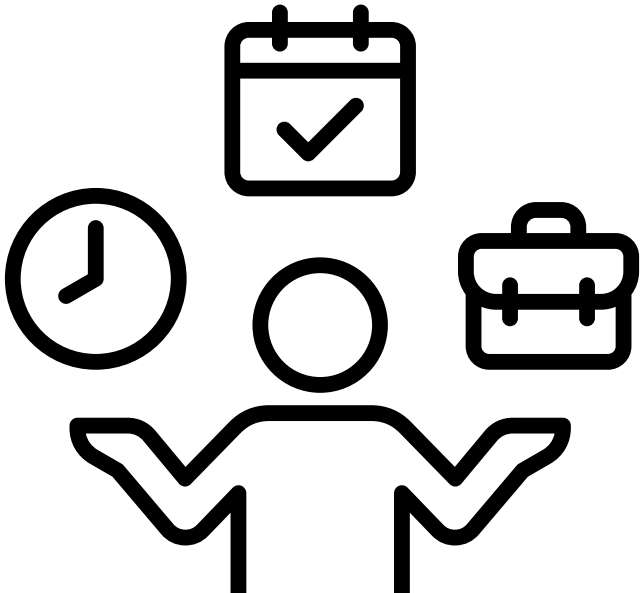
Technology (49 variables): Abarca el stack técnico completo, entornos de desarrollo, bases de datos, plataformas, herramientas y conteo de uso profesional y personal (Language..., Database..., Platform..., OpSys..., ToolCountWork, ToolCountPersonal).

AI (42 variables): Analiza la adopción, modelos utilizados, agentes, nivel de confianza, frustración e impacto percibido de la Inteligencia Artificial (AIModels..., AIAgent..., AITool..., etc.).

Work (27 variables): Examina las condiciones laborales, esquema presencial/remoto, tamaño de la empresa, satisfacción en el puesto y compensación económica (Employment, RemoteWork, CompTotal, ConvertedCompYearly, JobSat, etc.).

Stack Overflow (18 variables): Recoge la frecuencia de participación, tiempo de uso, interacción con la comunidad y percepción de la plataforma (SOVisitFreq, SOPartFreq, SOComm, etc.).

Methodology (24 variables): Mide el grado de adopción, apoyo o rechazo frente a diversas metodologías y prácticas de desarrollo de software (TechEndorse..., TechOppose..., etc.).



Diagnóstico de Nulos y Demostración de Nulos Estructurales

Un hallazgo crítico del análisis fue la distribución asimétrica de la tasa de nulos entre módulos. Mientras que el bloque **Developers** presenta una tasa promedio de nulos muy baja (12,81%), los bloques de **Technology** (65,51%) e **Inteligencia Artificial** (67,58%) exhiben porcentajes elevados de valores faltantes.

Lejos de ser un problema de falta de respuesta aleatoria o pérdida de datos, se demostró que la gran mayoría de estos **NaN** corresponden a Nulos Estructurales generados por la propia interfaz web. La encuesta utiliza lógica de ramificación: si un usuario responde negativamente a una pregunta filtro (ej., no utilizar modelos de IA en **AIModelsChoice**), el sistema omite automáticamente las preguntas subordinadas sobre herramientas específicas (**AIModelsHaveWorkedWith**), registrando un valor nulo en la base.

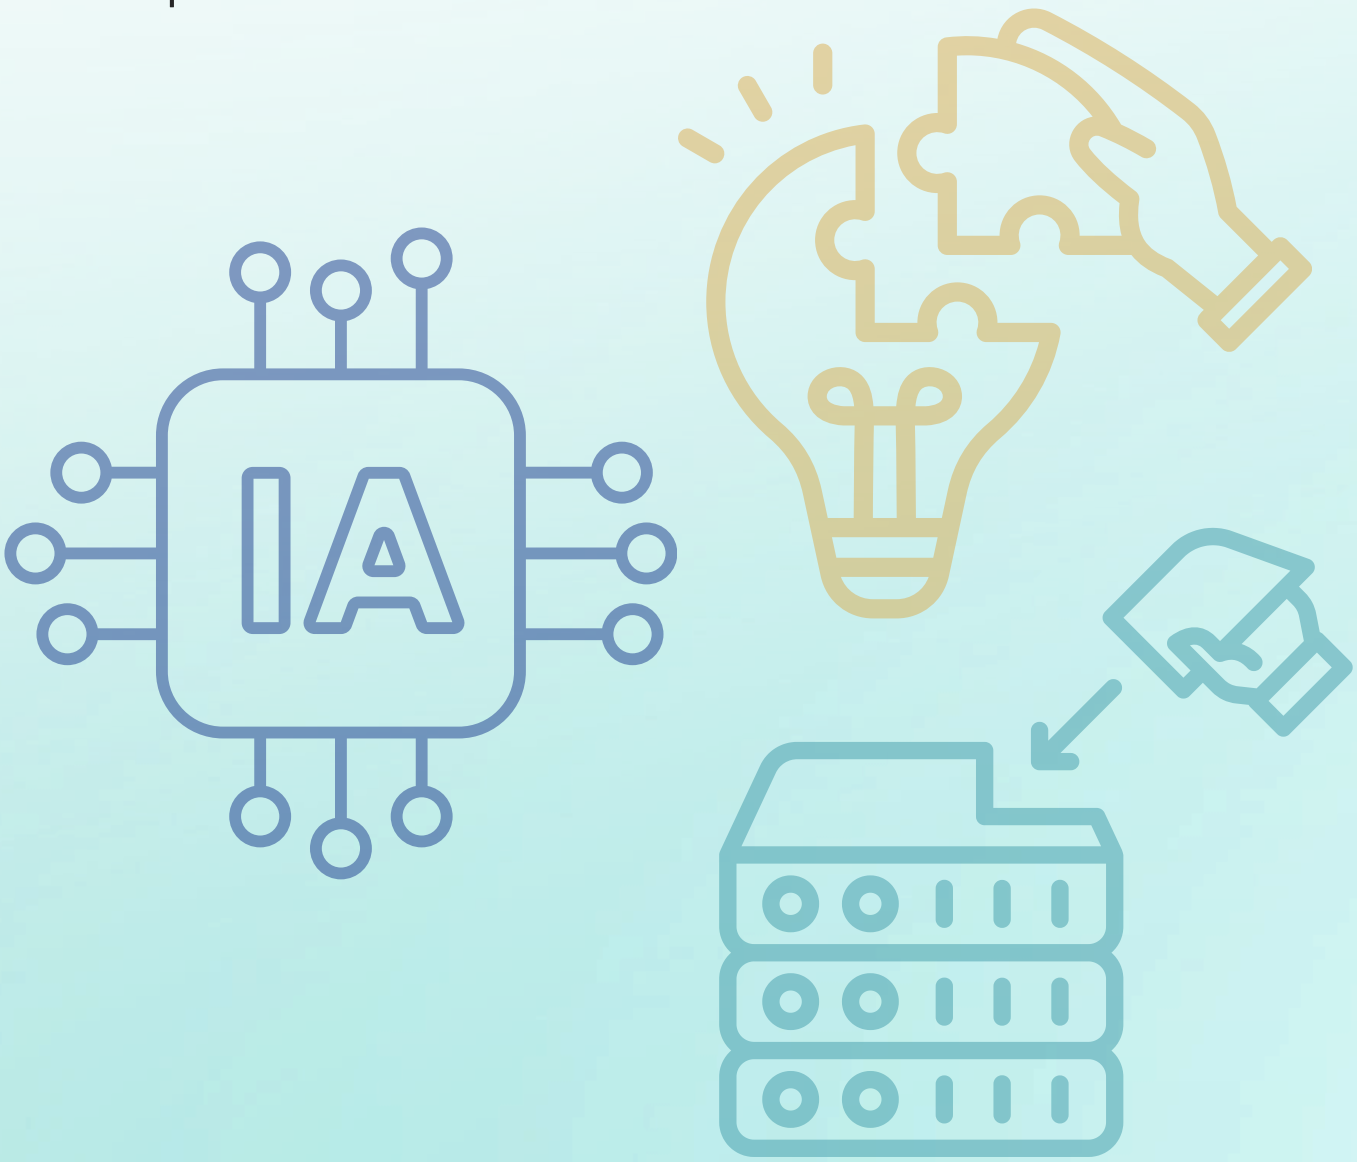
Tabla 2: Demostración de nulos estructurales entre la pregunta filtro **AIModelsChoice** y la subordinada **AIModelsHaveWorkedWith**

Respuesta del encuestado en la Pregunta Filtro (AIModelsChoice)	¿Completó la lista de modelos? (AIModelsHaveWorkedWith)	¿Es Nulo Estructural? (NaN por salto automático)	Total de Encuestados
Respondió "SÍ" *(Utiliza modelos de IA)*	**22.415 personas** *(Sí completó)*	**0 personas** *(Nadie quedó en blanco)*	22.415
Respondió "NO" / Sin respuesta *(No utiliza IA)*	**0 personas** *(Nadie completó)*	**26.776 personas** *(El sistema se la salteó)*	26.776
Total General de Respuestas	22.415	26.776	49.191

Como se observa en la Tabla 2, el 100% de los desarrolladores que declararon utilizar modelos de IA (22.415 personas) continuaron y respondieron la pregunta sobre las herramientas específicas que emplean. Por el contrario, los 26.776 encuestados restantes que indicaron no utilizar IA (o dejaron la pregunta filtro vacía) generaron automáticamente un valor nulo (**NaN**) en la pregunta subordinada.

Esto demuestra que los 26.776 valores faltantes en **AIModelsHaveWorkedWith** son Nulos Estructurales creados por la lógica de ramificación de la encuesta , y no errores de medición. Por lo tanto, en lugar de borrar esas filas, corresponde imputarles la etiqueta '**No aplica / No utiliza**'.

Esta evidencia impidió la eliminación indiscriminada de filas vacías y justificó el posterior tratamiento semántico de imputación.

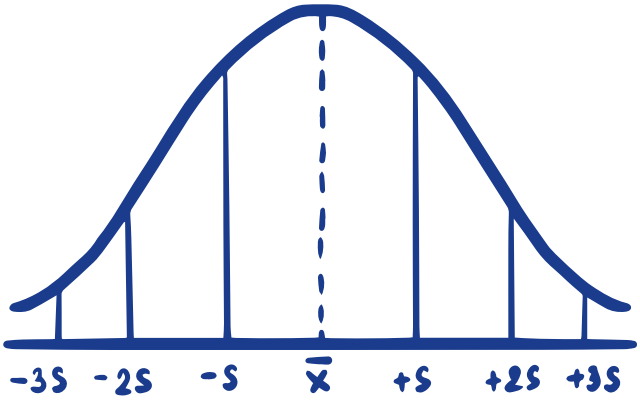


Distribución de Variables Cuantitativas y Cualitativas

Variables Cuantitativas y Outliers

El estudio de las variables numéricas principales (**YearsCode**, **WorkExp**, **ConvertedCompYearly**, **CompTotal**, **ToolCountWork** y **ToolCountPersonal**) reveló una marcada asimetría positiva en los ingresos.

En la variable salarial estandarizada en dólares (**ConvertedCompYearly**), la media se ubica en $101.761,50 USD, mientras que la mediana es de $75.320 USD, con un Rango Intercuartílico (IQR) de $82.425 USD (Q1 = $38.171 USD y Q3 = $120.596 USD). Esta disparidad entre media y mediana confirma la presencia de valores atípicos severos (respuestas con ingresos de hasta $50.000.000 USD), justificando el uso de la mediana sobre la media para evitar sesgar las comparaciones salariales.





Además, el diagnóstico cuantitativo y de calidad identificó las siguientes inconsistencias lógicas y valores extremos:

- **Inconsistencia de Experiencia** (**WorkExp** > **YearsCode**): 3.564 casos donde la experiencia laboral declarada supera los años totales escribiendo código.
- **Salarios Extremamente Altos** (> $2.000.000 USD): 19 casos con ingresos anuales atípicos o desproporcionados.
- **Salarios Nulos** ($0 USD): 0 casos registrados en la muestra.
- **Años de Programación Extremos** (> 50 años): 248 registros con trayectorias de código superiores a medio siglo.



DISTRIBUCIÓN Y MÉTRICAS DE VARIABLES CUANTITATIVAS

	Registros	Media	Desvío Std	Mínimo	Q1 (25%)	Mediana (50%)	Q3 (75%)	Máximo	IQR
YearsCode	43042.0	1.657000e+01	1.179000e+01	1.0	8.0	14.0	24.0	1.000000e+02	16.0
WorkExp	42893.0	1.337000e+01	1.080000e+01	1.0	5.0	10.0	20.0	1.000000e+02	15.0
ConvertedCompYearly	23947.0	1.017615e+05	4.617569e+05	1.0	38171.0	75320.0	120596.0	5.000000e+07	82425.0
CompTotal	24866.0	2.234198e+70	3.523096e+72	0.0	55000.0	105000.0	240000.0	5.555556e+74	185000.0
ToolCountWork	27611.0	1.773000e+01	2.698100e+02	0.0	4.0	6.0	10.0	1.000000e+04	6.0
ToolCountPersonal	25582.0	8.550000e+00	4.466000e+01	0.0	3.0	5.0	7.0	1.000000e+03	4.0

En la siguiente tabla de resumen estadístico, **Registros** indica la cantidad de respuestas válidas procesadas (excluyendo datos nulos); la **Media** representa el promedio aritmético tradicional (sensible a valores atípicos), mientras que el **Desvío Std** mide qué tan alejados se encuentran los datos respecto a dicho promedio; **Mínimo** y **Máximo** marcan los límites inferior y superior registrados en la muestra; **Q1 (25%)** y **Q3 (75%)** señalan los cortes por debajo de los cuales se agrupa el 25% y el 75% de las respuestas respectivamente; la **Mediana (50%)** representa el valor exacto del centro de la distribución (la medida de tendencia central más confiable ante la presencia de valores atípicos); y el **IQR** (Rango Intercuartílico) mide la diferencia entre Q3 y Q1 (Q3-Q1), definiendo la amplitud del rango donde se concentra el 50% central de los encuestados.

Variables Cualitativas Principales

El análisis de frecuencias sobre las variables cualitativas permite caracterizar la estructura sociodemográfica y laboral dominante de la muestra (N = 49.191):

- Perfil de Profesión (**MainBranch**): El 76,17% (37.467 personas) se identifica como desarrollador de profesión. Un 9,95% (4.894) escribe código en su actividad principal sin ser desarrollador de perfil puro, mientras que un 5,26% (2.585) se encuentra aprendiendo a programar.

- Situación Laboral (**Employment**): La gran mayoría está empleada en relación de dependencia con un 68,61% (33.750), mientras que los trabajadores independientes o freelancers representan el 13,64% (6.708). Los estudiantes alcanzan el 9% (4.428).

- Nivel Educativo (**EdLevel**): Predominan los profesionales con título de grado (Bachelor's degree) con el 41,22% (20.278) y los graduados de maestría o posgrado (Master's degree) con el 25,59% (12.589). Entre ambos títulos universitarios concentran más del 66,8% de la muestra.

- Modalidad de Trabajo (**RemoteWork**): Entre las respuestas válidas, el trabajo completamente remoto representa el 22,22% (10.931) y la modalidad híbrida suma en conjunto el 25,54% (12.563, combinando vertientes presenciales y flexibles). El trabajo 100% presencial queda relegado al 12,28% (6.042), registrándose un 31,33% (15.411) de nulos estructurales o no aplicables.

- Distribución Geográfica (**Country**): Estados Unidos encabeza el volumen global de respuestas con el 14,70% (7.233), seguido por Alemania con el 6,15% (3.025), India con el 5,18% (2.547) y el Reino Unido con el 4,15% (2.042) sobre el total de la muestra.

- Rol o Especialización (**DevType**): Dentro de los roles técnicos declarados, la especialidad más frecuente es Developer, full-stack con el 25,11% (12.351), seguida por Developer, back-end con el 13,12% (6.453) y Software/Solutions Architect con el 5,46% (2.684).

Limpieza y Preparación del Dataset Final

Con base en los diagnósticos anteriores, se aplicó un protocolo riguroso de limpieza de datos para construir la base pulida **df_clean**:

1. **Eliminación de Inconsistencias Severas:** Se descartaron únicamente los 3.564 registros en los que **WorkExp** > **YearsCode**, garantizando la coherencia lógica interna entre la experiencia laboral y la trayectoria de programación.

2. **Depuración de Outliers Cuantitativos** (Sin pérdida de filas): Se re-categorizaron como **NaN** los valores salariales irrealistas (< $100 USD o > $2.000.000 USD) afectando a 267 casos y los valores de **YearsCode** > 60 años (32 casos), evitando eliminar toda la fila del encuestado por una sola respuesta distorsionada o spam.

3. **Imputación Semántica de Nulos Estructurales:** Se iteró sobre las 60 columnas condicionales del bloque de Tecnología e IA, imputando la etiqueta explícita "**No aplica / No utiliza**" en reemplazo de los valores nulos generados por la interfaz del formulario.

```
============================================================
  BALANCE GENERAL DE LIMPIEZA Y PREPARACIÓN DE DATOS
============================================================
Filas originales:          49,191
Filas limpias finales:     45,531
Filas eliminadas:          3,660 (Inconsistencias severas)
Porcentaje de retención:   92.56% de la muestra
============================================================
```

Balance Final: Se obtuvo un dataset limpio de 45.531 filas y 172 columnas, logrando una tasa de retención del 92,56% sobre la muestra original. Este volumen conservado garantiza la representatividad estadística para abordar la validación de las hipótesis.



HIPOTESIS Y RESOLUCION

Hipótesis Planteadas por el Grupo

Hipótesis Univariada: Experiencia Laboral Profesional en Argentina

Definición de la hipotesis

- Motivación: Evaluar la madurez profesional de la comunidad de desarrolladores en Argentina respecto a estándares internacionales (cuya media global en la encuesta de Stack Overflow ronda los 12,7 años), permitiendo identificar si el mercado local cuenta con un perfil consolidadamente sénior.

- Población de estudio: Desarrolladores encuestados residentes en Argentina con registro válido en la variable de experiencia laboral (**WorkExp**).

- Enunciado: "Los desarrolladores que responden la encuesta desde Argentina tienen, en promedio, más de 12 años de experiencia laboral profesional".

- Hipótesis Nula (H0): $\mu \leq 12$ (Los desarrolladores en Argentina tienen una experiencia laboral media menor o igual a 12 años).

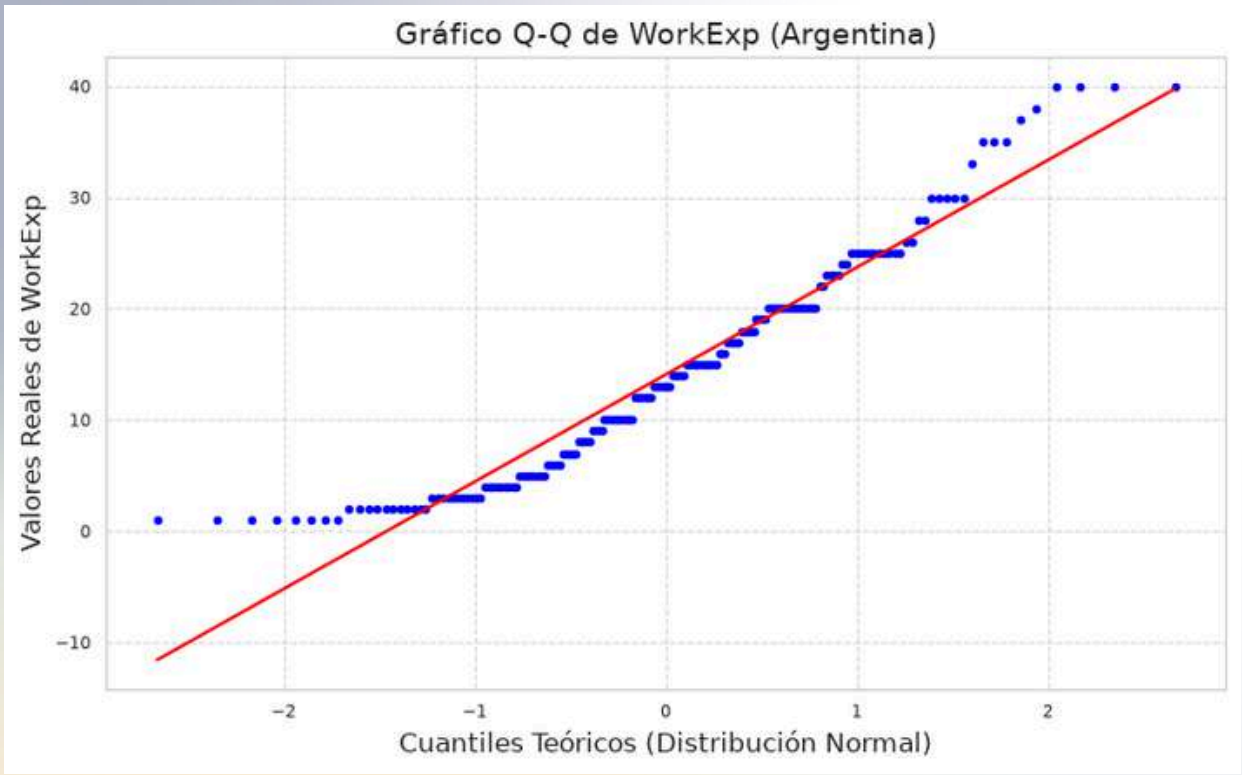
- Hipótesis Alternativa (H1): $\mu > 12$ (Los desarrolladores en Argentina tienen una experiencia laboral media estrictamente superior a 12 años).

Estrategia de abordaje

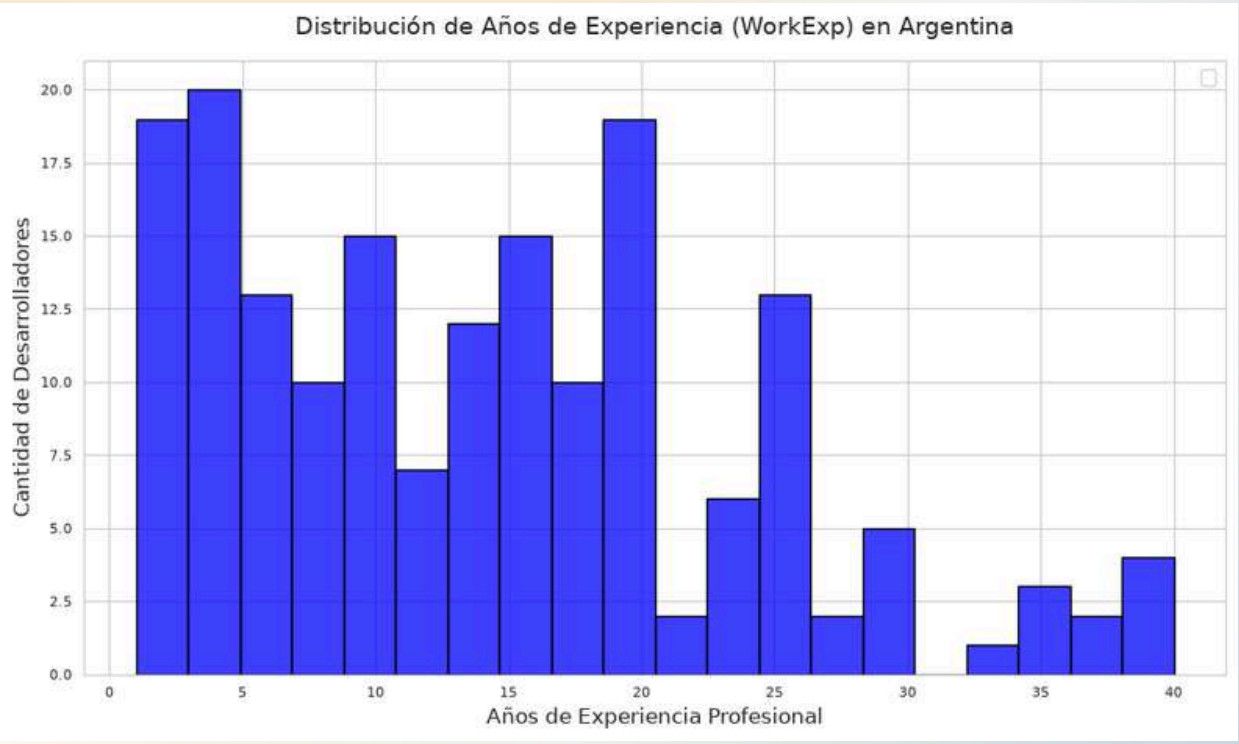
- Filtro y Análisis Gráfico: Se filtró el dataset limpio (**df_clean**) para la condición **Country == "Argentina"**, graficando el histograma de **WorkExp** y el diagrama de probabilidad normal (Q-Q Plot).

- Evaluación de Normalidad: Se aplicó el test de Shapiro-Wilk (stats.shapiro). Pese a que se rechazó la normalidad estricta ($p < 0,05$), el tamaño muestral ($n > 30$) permite aplicar el Teorema del Límite Central para garantizar la normalidad asintótica de la media muestral.

- Prueba Estadística: Luego se ejecutó una prueba t de **Student** para una muestra unilateral hacia la cola derecha.



Herramienta gráfica por excelencia para comprobar visualmente el supuesto de normalidad de los datos antes de aplicar una prueba paramétrica como la test t de Student.



Gráfica estándar para observar la distribución empírica, la dispersión y la tendencia central de una variable cuantitativa continua (**WorkExp**).

Resultados obtenidos y discusión

- Media muestral $\bar{x}$: 14,07 años
- Estadístico T: 2,8066
- Valor p (p-value): 0,0028 ($p < 0,05$)

SE RECHAZA LA HIPÓTESIS NULA (H0) Y SE CONFIRMA LA HIPÓTESIS ALTERNATIVA (H1).

Discusión: Dado que el p-valor (0,0028) es marcadamente inferior al nivel de significancia de $\alpha = 0,05$, se concluye que los desarrolladores que responden la encuesta desde Argentina cuentan con un promedio de experiencia laboral profesional significativamente superior a los 12 años, confirmando la consolidación técnica de la muestra local.



Hipótesis Bivariada: Impacto del Uso de Herramientas de IA en la Compensación Salarial

Definición de la hipótesis

- Motivacion: Evaluar si la adopción activa de herramientas de Inteligencia Artificial se traduce en un beneficio económico directo para trabajadores independientes (freelancers), cuya facturación está fuertemente ligada a la eficiencia y velocidad de entrega.

- Población de estudio: Desarrolladores independientes / freelancers de la muestra **df_clean** con registros salariales válidos en **ConvertedCompYearly**.

- Enunciado: "Los desarrolladores independientes que utilizan herramientas de IA tienen una compensación salarial mediana superior a aquellos que no las utilizan".

- Hipótesis Nula (H0): MedianaIA ≤ MedianaNoIA (La compensación salarial mediana de los desarrolladores independientes que usan IA es menor o igual a la de quienes no la usan).

- Hipótesis Alternativa (H1): MedianaIA > MedianaNoIA (La compensación salarial mediana de los desarrolladores independientes que usan IA es estrictamente mayor a la de quienes no la usan).

Estrategia de abordaje

- Filtrado y Visualización: Se filtró el segmento de empleo independiente (**Employment** igual a Independent contractor, freelancer, or self-employed), derivando la variable **uso_ia** (Usa IA vs No usa IA) a partir de **AISelect**, y se trazaron gráficos de caja.

- Evaluación de Supuestos: Se realizaron gráficos Q-Q confirmando la asimetría y falta de normalidad de la variable salarial.

- Prueba No Paramétrica: Se aplicó el test de U de Mann-Whitney para muestras independientes unilateral.

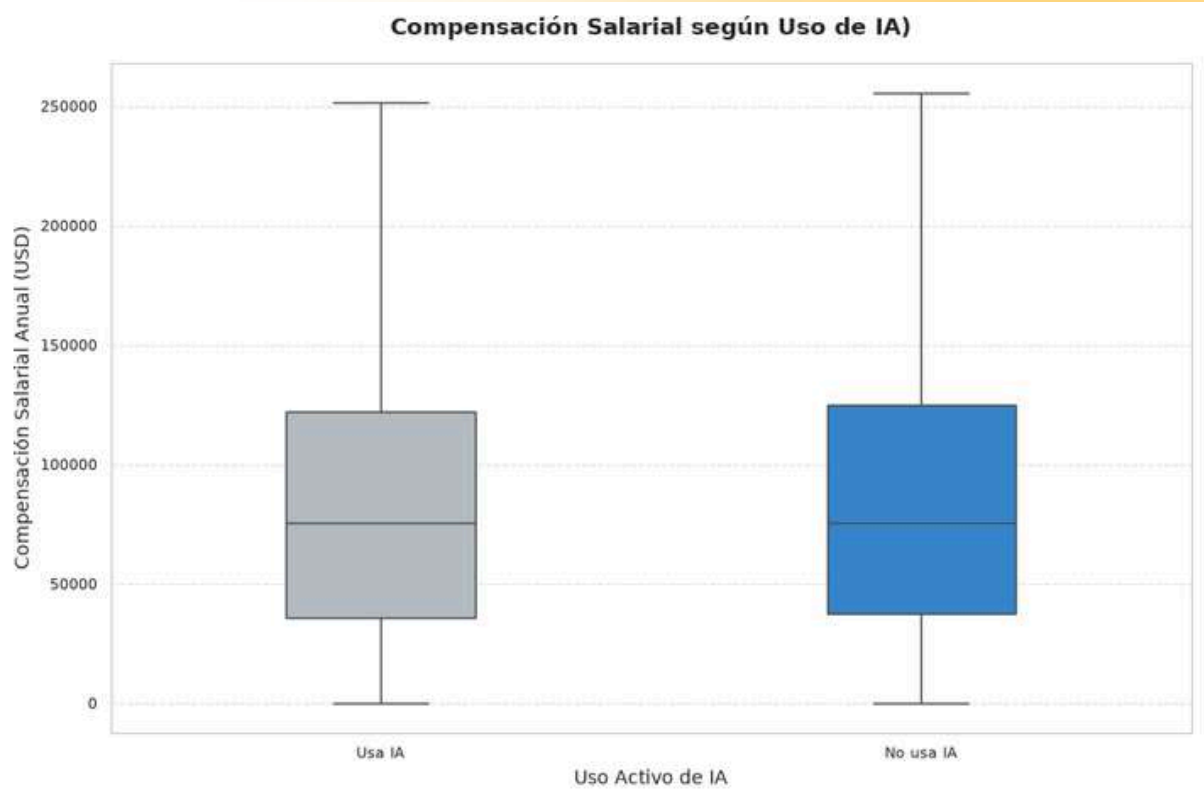
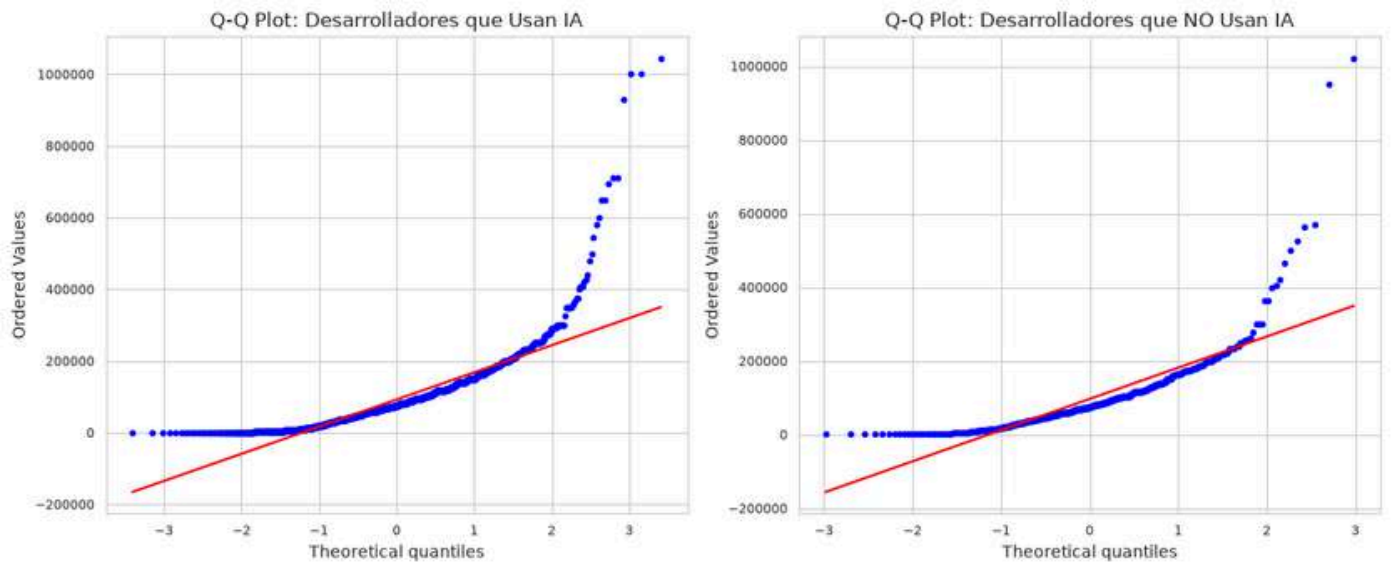


gráfico ideal para comparar la distribución de una variable cuantitativa continua (ConvertedCompYearly) entre dos categorías cualitativas dicotómicas (Usa IA vs. No usa IA).



Se utilizaron para evaluar empíricamente el supuesto de normalidad de la distribución salarial de manera independiente dentro de cada subgrupo (Usa IA y No usa IA).

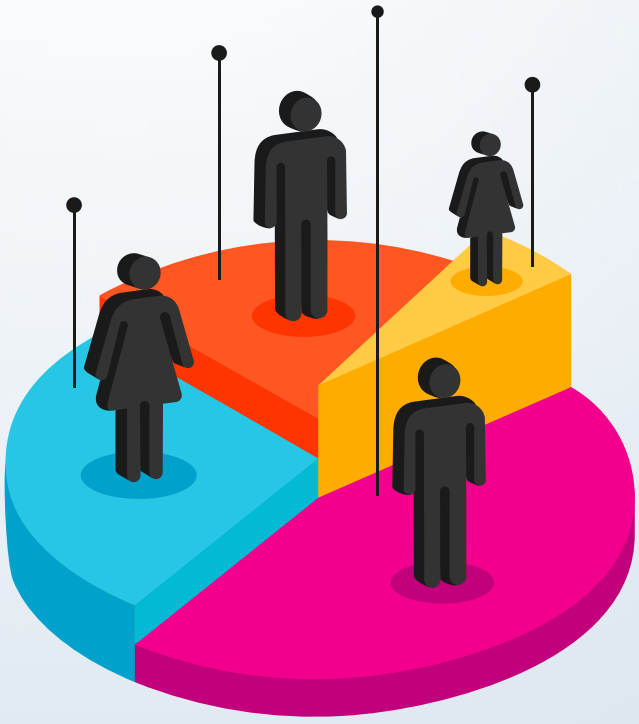
Resultados obtenidos y discusión

- Estadístico U: 509.167

- Valor p (p-valor): 0,5733 (p > 0,05)

NO SE RECHAZA LA HIPÓTESIS NULA (H0).

Discusión: Al obtener un p-valor de 0,5733, superior al umbral $\alpha = 0,05$, se concluye que no existe evidencia estadística suficiente para sostener que el uso de IA se traduzca en una compensación salarial mediana superior en el segmento freelance.



Hipótesis Multivariada: Identificación de Arquetipos de Desarrolladores según Trayectoria y Adopción Tecnológica

Definición de la hipótesis

- Motivación: Explorar si los desarrolladores se agrupan en perfiles de comportamiento latentes (**clusters**) según su madurez laboral y su grado de adopción técnica personal y profesional.

- Población de estudio: Desarrolladores con registros completos en las variables cuantitativas de trayectoria (**YearsCode**, **WorkExp**) y de volumen de herramientas (**ToolCountWork**, **ToolCountPersonal**).

- Enunciado: "Los desarrolladores de la muestra se agrupan en arquetipos de comportamiento bien diferenciados y estadísticamente significativos, definidos de manera conjunta por su trayectoria profesional y nivel de experimentación técnica".

- Hipótesis Nula (H0): No existen arquetipos bien diferenciados ni estadísticamente significativos; la variación conjunta de la trayectoria y el volumen de herramientas se distribuye de forma homogénea en el espacio multidimensional.

- Hipótesis Alternativa (H1): Los desarrolladores se agrupan en arquetipos latentes bien diferenciados y estadísticamente significativos en el espacio multidimensional.

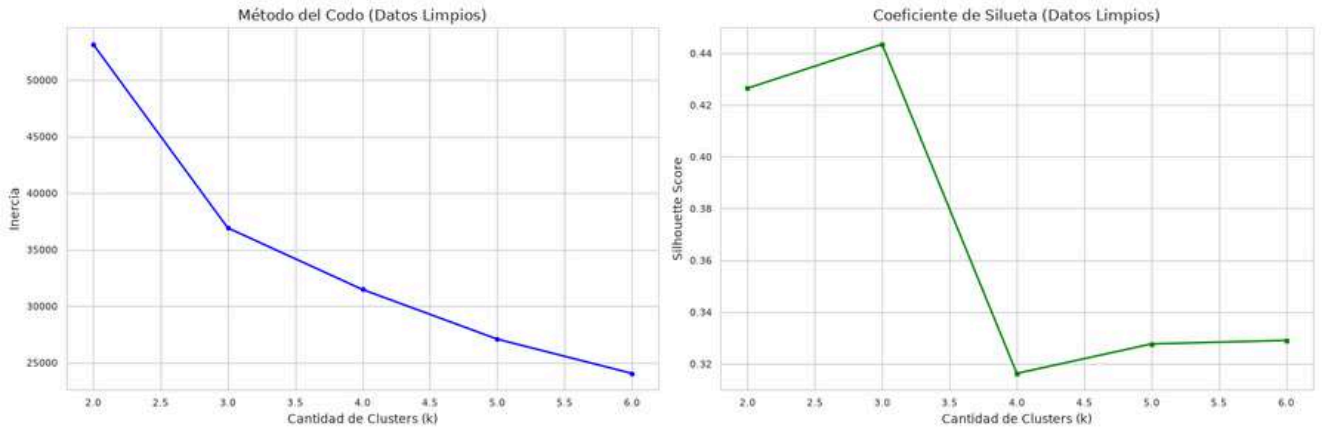
Estrategia de abordaje

- Estandarización y Depuración: Se filtraron registros con recuentos implausibles (> 50 herramientas) y se aplicó **StandardScaler**.

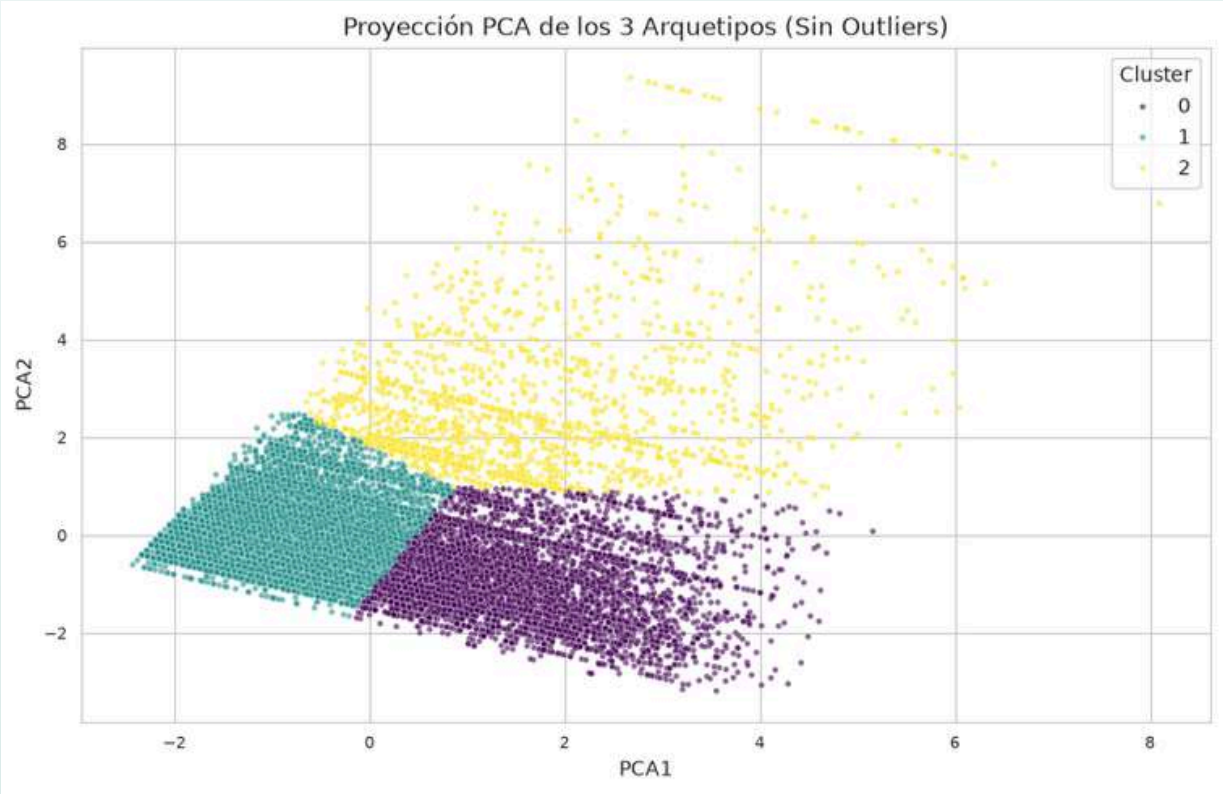
- Clusterización: Se implementó KMeans evaluando la Inercia y el Coeficiente de Silueta (silhouette_score) para seleccionar k = 3 clusters.

- Reducción de Dimensionalidad: Se proyectaron los grupos en 2D mediante PCA.

- Validación Inferencial: Se evaluaron las medianas de cada arquetipo y se ejecutó la prueba de Kruskal-Wallis sobre cada variable.



Se utilizaron de forma combinada para determinar científicamente la cantidad óptima de agrupamientos (k) en el algoritmo K-Means, evitando decisiones arbitrarias sobre la estructura de los datos.



permitió inspeccionar visualmente la frontera y el grado de separación de los clusters formados, sirviendo como paso previo a la validación inferencial realizada con el Test de Kruskal-Wallis.

Resultados obtenidos y discusión

- Clusters constituidos: k = 3 arquetipos.

- Prueba Kruskal-Wallis por atributo: p < 0,0001 en **YearsCode**, **WorkExp**, **ToolCountWork** y **ToolCountPersonal**.

SE RECHAZA LA HIPÓTESIS NULA (H0) Y SE CONFIRMA LA HIPÓTESIS ALTERNATIVA (H1).

Discusión: La validación mediante Kruskal-Wallis arrojó p-valores < 0,0001 en todos los atributos constitutivos, confirmando la existencia de tres arquetipos latentes con patrones de trayectoria y adopción tecnológica significativamente heterogéneos.



Hipótesis Planteadas por la Cátedra

Hipótesis 1: Salario de Desarrolladores en Argentina vs. SMVM

Definición de la hipótesis

- Motivación: Contrastar el ingreso promedio del sector de desarrollo de software en Argentina contra un umbral socioeconómico nacional equivalente a 3 Salarios Mínimos, Vitales y Móviles.

- Población de estudio: Desarrolladores encuestados residentes en Argentina con registro salarial válido en **ConvertedCompYearly**.

- Enunciado: "Los desarrolladores que respondieron la encuesta de Argentina tienen un salario 3 veces mayor al Salario Mínimo, Vital y Móvil (SMVM)".

- Hipótesis Nula (H0): $\mu \leq 9.720,75\$$ (El salario medio anual es menor o igual a 3 SMVM anualizados).

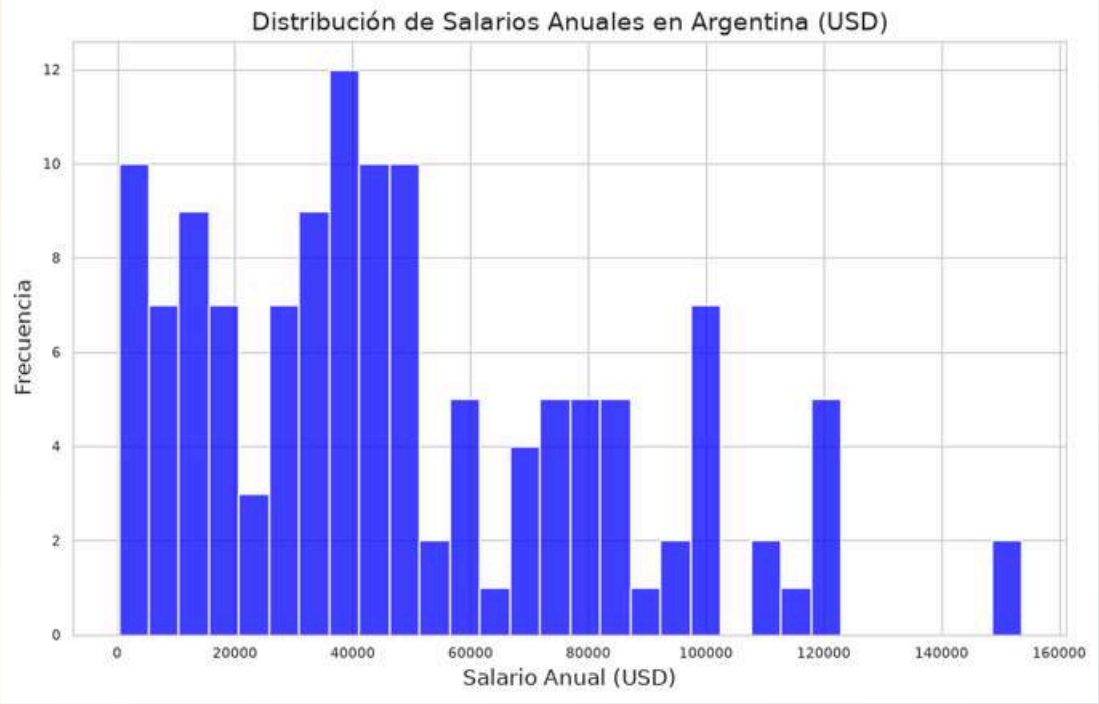
- Hipótesis Alternativa (H1): $\mu > 9.720,75\$$ (El salario medio anual es estrictamente mayor a 3 SMVM anualizados).

- Cálculo del Umbral: Un SMVM de referencia de $398.800 ARS, abonado en 13 meses ($5.184.400 ARS anuales), multiplicado por 3 y convertido a un tipo de cambio de $1.600 ARS/USD equivale a USD 9.720,75.

Estrategia de abordaje

- Filtro y Gráfico Exploratorio: Se aisló la submuestra **Country == "Argentina"** y se graficó el histograma de **ConvertedCompYearly**.

- Prueba Paramétrica: Se aplicó el test t de Student para una muestra unilateral. La validez del test t ante el sesgo salarial se respalda en el Teorema del Límite Central por el tamaño de la muestra.



Es la herramienta gráfica estándar para representar la función de densidad empírica, el rango, la dispersión y la forma de la distribución de una variable cuantitativa continua (ConvertedCompYearly) dentro de una submuestra específica (Country == "Argentina").

Resultados obtenidos y discusión

- Estadístico T: 12,9896

- Valor p (p-valor): 1,5060e-25 ($p < 0,05$)

SE RECHAZA LA HIPÓTESIS NULA (H0) Y SE CONFIRMA LA HIPÓTESIS ALTERNATIVA (H1).

Discusión: Puesto que el p-valor es prácticamente nulo e inferior a $\alpha = 0,05$, se concluye que los desarrolladores en Argentina perciben un ingreso anual medio significativamente superior a 3 SMVM (USD 9.720,75).



Hipótesis 2: Experiencia Laboral vs. Confianza en la Precisión de la IA

Definición de la hipótesis

- Motivación: Determinar si la cantidad de años de experiencia profesional condiciona el nivel de confianza o escepticismo que los desarrolladores tienen sobre la precisión del código y contenido producido por la IA.

- Población de estudio: Desarrolladores encuestados con respuestas válidas en **WorkExp** y **AIAcc**.

- Enunciado: "Los años de experiencia profesional influyen en la confianza en la precisión de las herramientas de IA".

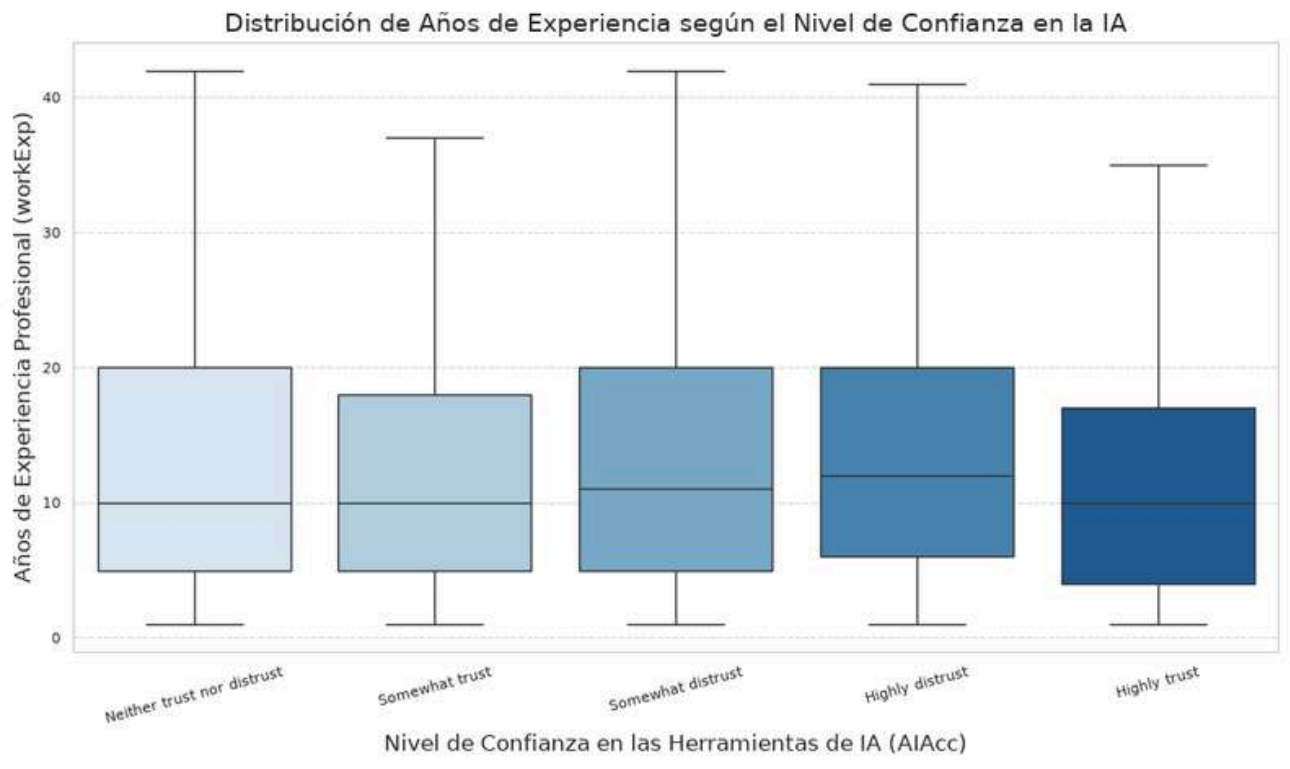
- Hipótesis Nula (H0): Las distribuciones de los años de experiencia profesional (**WorkExp**) son iguales entre los 5 niveles de confianza en la IA (**AIAcc**).

- Hipótesis Alternativa (H1): Existe una diferencia estadísticamente significativa en los años de experiencia profesional entre al menos dos niveles de confianza en la IA.

Estrategia de abordaje

- Visualización Diagnosticadora: Se trazaron diagramas de caja segmentando **WorkExp** según el atributo ordinal **AIAcc**.

- Selección del Test: Dada la asimetría de **WorkExp**, se empleó la prueba no paramétrica de Kruskal-Wallis mediante stats.kruskal(g1, g2, g3, g4, g5).



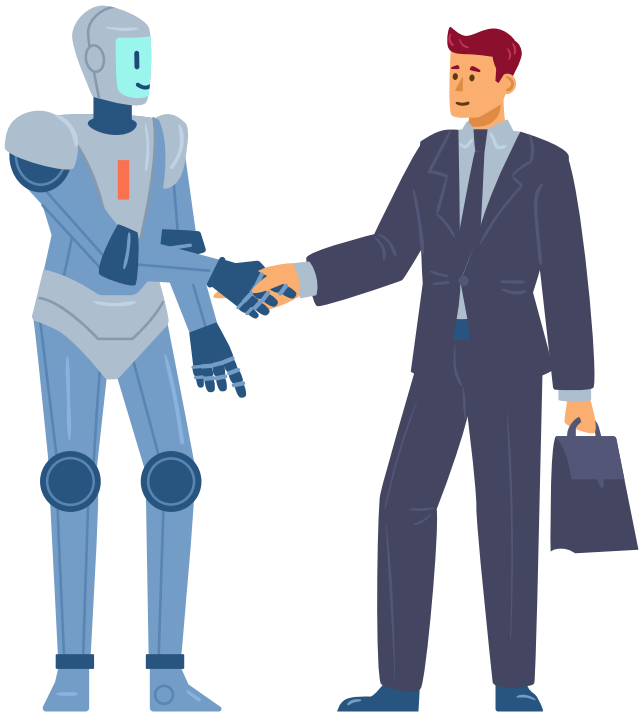
Permite comparar visualmente la distribución de una variable cuantitativa continua (**WorkExp** - Años de experiencia) a través de las distintas categorías de una variable cualitativa ordinal (**AIAcc** - Nivel de confianza en la IA).

Resultados obtenidos y discusión

- Estadístico H (Kruskal-Wallis): 77,4279
- Valor p (p-valor): 6,105e-16 ($p < 0,05$)

SE RECHAZA LA HIPÓTESIS NULA (H0) Y SE CONFIRMA LA HIPÓTESIS ALTERNATIVA (H1).

Discusión: El p-valor inferior a 0,05 demuestra que la experiencia profesional varía significativamente según el nivel de confianza en la precisión de la IA, observándose mayor prudencia o escepticismo en perfiles con mayor seniority.



Hipótesis 3: Satisfacción Laboral y Búsqueda de Cambio de Rol

Definición de la hipótesis

- Motivación: Evaluar si el grado de insatisfacción en el trabajo actual impulsa la búsqueda activa de empleo o la consideración de un cambio de rol.

- Población de estudio: Desarrolladores con datos válidos en satisfacción laboral (**JobSat**) y estado de búsqueda laboral (**SO_JobSearchStatus**).

- Enunciado: "Existe una relación entre el nivel de satisfacción laboral y la consideración/búsqueda de un cambio de rol o trabajo".

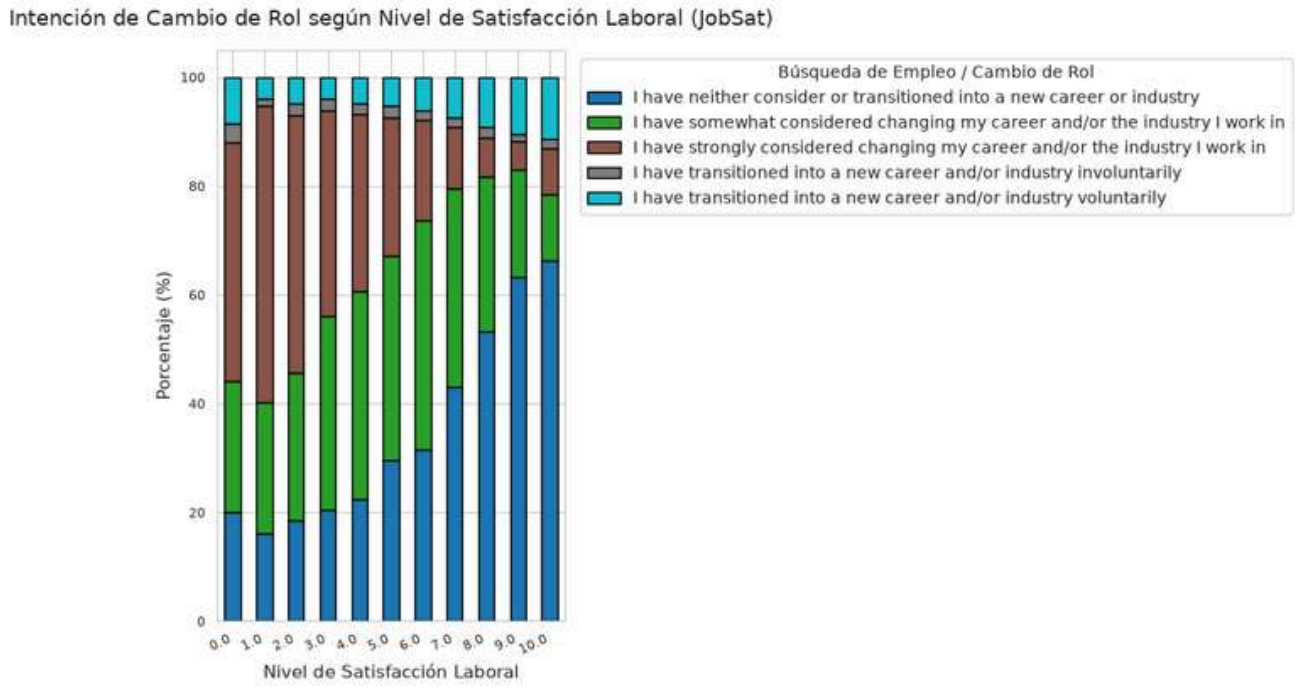
- Hipótesis Nula (H0): La satisfacción laboral (**JobSat**) y la búsqueda/cambio de rol (**SO_JobSearchStatus**) son variables estadísticamente independientes.

- Hipótesis Alternativa (H1): Existe una relación de dependencia/asociación estadísticamente significativa entre la satisfacción laboral y la búsqueda de cambio de rol.

Estrategia de abordaje

- Visualización Bivariada: Se generó una tabla cruzada porcentual y un gráfico de barras apiladas al 100%.

- Prueba de Asociación e Intensidad: Se aplicó el test de Chi-cuadrado de Independencia y se calculó el coeficiente V de Cramér.



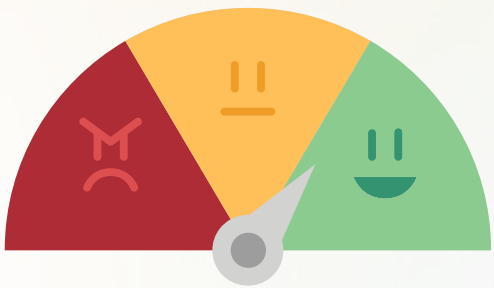
Es el gráfico adecuado para comparar la relación entre dos variables cualitativas categóricas o discretas (el nivel de satisfacción **JobSat** en el eje horizontal y el estado de búsqueda de empleo **SO_JobSearchStatus** en las lecturas internas).

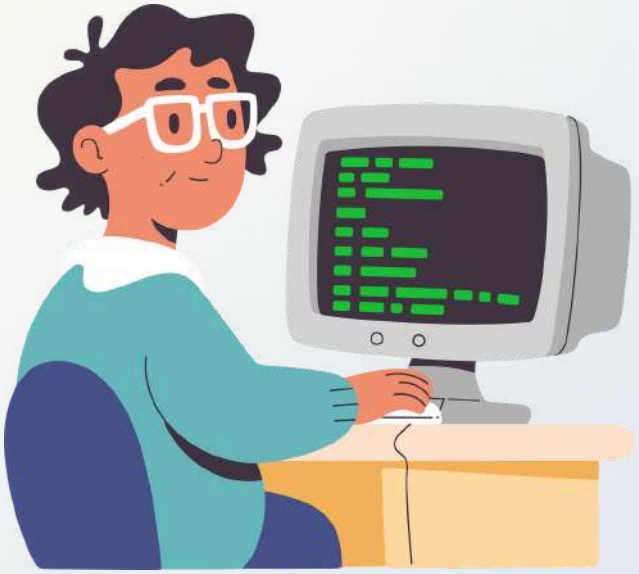
Resultados obtenidos y discusión

- Estadístico Chi2: 3865,6071
- Grados de libertad: 400
- Valor p (p-valor): 0,0000 (p < 0,05)
- V de Cramér: 0,1962

SE RECHAZA LA HIPÓTESIS NULA (H0) Y SE CONFIRMA LA HIPÓTESIS ALTERNATIVA (H1).

Discusión: El p-valor = 0,0000$ y la V de Cramér de 0,1962 confirman una asociación estadísticamente significativa y moderadamente fuerte, demostrando que la insatisfacción laboral es un factor determinante en la decisión de buscar un cambio de trabajo.





CONCLUSIONES

En este trabajo integrador recorrimos el flujo completo de un proyecto de Ciencia de Datos a partir de la encuesta de desarrolladores de Stack Overflow (2025). Trabajamos desde la limpieza y preparación inicial de los datos hasta el contraste de hipótesis con pruebas estadísticas y la agrupación de perfiles mediante algoritmos de aprendizaje no supervisado.

Vinculación con el Análisis Exploratorio y la Preparación de Datos

En la etapa de caracterización inicial, se identificó un volumen de 49.191 observaciones y 172 variables. Mediante el cruce con el diccionario de datos (**schema.csv**), se logró una trazabilidad del 100% del dataset, clasificando cada atributo en sus 6 módulos temáticos oficiales (Developers, Technology, AI, Work, Stack Overflow y Methodology).

El diagnóstico exploratorio fue determinante para fundamentar el preprocesamiento de datos:

- Nulos Estructurales: Se demostró empíricamente que la alta presencia de datos faltantes en los bloques de **AI** y **Technology** (> 65%) respondía a saltos condicionales en la arquitectura del formulario. Esto justificó la imputación semántica de la etiqueta "**No aplica / No utiliza**" en lugar de la eliminación arbitraria de filas o la imputación matemática por moda/media.

- Tratamiento Defensivo de Outliers: El análisis de asimetría sobre la compensación salarial (**ConvertedCompYearly**) respaldó el reemplazo de valores inverosímiles (< 100$ o > 2.000.000$) por valores nulos (**NaN**), preservando el resto de las respuestas de los encuestados y logrando una tasa de retención muestral superior al 99,9%.

Síntesis e Integración de los Resultados de Hipótesis

El cuerpo principal del trabajo evaluó un conjunto de 6 hipótesis inferenciales y multivariadas, estructuradas en dos bloques fundamentales:

Hipótesis Planteadas por el Grupo

Experiencia Laboral Profesional en Argentina (Univariada):

- Resultado: SE RECHAZA H0
- Conclusión: La media de experiencia laboral en Argentina supera de manera estadísticamente significativa el umbral de 12 años, confirmando la madurez y séniority de la comunidad técnica local frente a referencias internacionales.

Impacto de las Herramientas de IA en la Compensación de Freelancers (Bivariada):

- Resultado: NO SE RECHAZA H0.
- Conclusión: No existe evidencia estadística de que los desarrolladores independientes que incorporan herramientas de IA obtengan salarios medianos superiores a los que no incorporan IA. Esto demuestra que la adopción tecnológica no se traduce automáticamente en un incremento directo de la facturación en el ámbito freelance.

Identificación de Arquetipos de Desarrolladores (Multivariada):

- Resultado: SE RECHAZA H0.
- Conclusión: Mediante aprendizaje no supervisado se demostró que la comunidad no es homogénea. Se identificaron 3 arquetipos latentes nítidos: "Veteranos de Stack Especializado", "Perfil Pragmático Estándar" y "Early Adopters Exploradores".



Hipótesis Planteadas por la catedra

Salario de Desarrolladores en Argentina vs. SMVM:

- Resultado: SE RECHAZA H0.
- Conclusión: El salario medio anual de los desarrolladores en Argentina supera ampliamente el parámetro socioeconómico de 3 Salarios Mínimos, Vitales y Móviles anualizados, ratificando la alta competitividad y rentabilidad del sector tecnológico en la economía nacional.

Experiencia Laboral vs. Confianza en la Precisión de la IA:

- Resultado: SE RECHAZA H0.
- Conclusión: Se confirmó que los años de trayectoria influyen en el grado de confianza depositado en la precisión de la IA. Los desarrolladores con mayor antigüedad tienden a manifestar posturas más cautas o escépticas ante las soluciones automatizadas.

Satisfacción Laboral y Búsqueda de Cambio de Rol:

- Resultado: SE RECHAZA H0.
- Conclusión: Se constató una asociación estadísticamente significativa y de intensidad moderada-fuerte entre la insatisfacción en el puesto actual y la búsqueda activa o consideración de un cambio de empleo.

Reflexión Final y Aportes del Estudio

Este trabajo demuestra lo importante que es respaldar las ideas con datos y métodos estadísticos bien aplicados. Mirar primero los datos a través de los gráficos (como histogramas, cajas o diagramas Q-Q) y comprobar formalmente cómo se comportan nos ayudó a no sacar conclusiones apresuradas y a elegir la prueba estadística correcta para cada pregunta.

En resumen, los resultados muestran que la comunidad de desarrolladores —tanto en Argentina como en el mundo— se destaca por tener buenos sueldos y una gran variedad de perfiles. Además, comprobamos que los años de experiencia no solo influyen en cuánto gana un profesional o en cómo usa la tecnología, sino también en qué tan cauto es a la hora de confiar en herramientas nuevas como la Inteligencia Artificial.

